

来源 leslie

本文为 2026 年全球半导体展望系列文章第一篇。

该系列文章将陆续推出，第二篇. 2026 全球半导体制造技术与市场展望，第三篇. 2026 全球存储技术与市场展望，第四篇. 2026 中国半导体制造与设备国产化展望，第五篇. 2026 全球与大 A 半导体投资建议，

本文摘要

2025 年，黄仁勋在 GTC 上掷地有声的「未来六个季度资料中心收入 5000 亿美元」预言，不仅是对市场的强心针，更是对整个算力产业链的总动员令。

然而，硝烟从未散去。2026 年开局的 CES，老黄直言 90% 的 ASIC 可能都会失败。

如此一来，战局愈发清晰，以英伟达为首的通用 GPU 阵营，与以博通（承载谷歌 TPU、Meta Mtia 等）、Marvell（承载 AWS Trainium 等）为代表的定制化 ASIC 阵营，在台积电 CoWoS 先进封装产能这一终极战略资源上，展开了寸土必争的争夺。

本报告将以 CoWoS 产能为唯一锚点，精确测算 2026 年 AI 算力晶片的出货格局，并首次进行系统性覆盘，验证此前预测的成败得失。

同时，我们将深入剖析 CES 上黄仁勋与苏姿丰描绘的技术蓝图，探讨「物理 AI 的 ChatGPT 时刻」对战局的深远影响，以及英伟达收购 Grop 这一关键棋步背后的战略意图。

结论将揭示：这场对决不仅是算力的比拼，更是生态、架构与供应链掌控力的全面战争。

第一章. 复盘 2025

在深入 2026 年战局前，必须对我们 2025 年的预测进行一次严苛的覆盘。所有的预测不去检讨不去复盘那都是妥妥的胡扯与耍流氓。

回顾笔者于 2025 年 1 月在知识星球发表的 2025 年全球半导体展望系列文章中『英伟达与博通的 AI 霸主之战 GPU 与 ASIC 的未来市场格局推演』一文 <https://t.zsxq.com/GHmhG>，其核心论点与数据推演，在过去一年中经历了市场的残酷检验。

先来看看预言精准之处：

1. **CoWoS 产能是绝对瓶颈与胜负手：**

2025 原文开篇即点出，2023 年英伟达因应 AI 爆发向台积电紧急加单 CoWoS，但产能仍严重不足，并精确追踪了 2023 年台积电与 Amkor 第二供应源的总出货量（约 63K/片）。

以 CoWoS 为核心稀缺资源进行供需测算的分析框架，在 2025 年同样被完全验证。

无论是英伟达 Blackwell 的放量，还是博通承接的谷歌 TPU、Meta Mtia 等 ASIC 大单，其出货上限无一不受制于台积电 CoWoS 的产能爬坡速度。

2025 原文中「CoWoS 的产能增幅，对应的不只是 AI 晶片出货量数量的增加，还叠加了 Interposer 面积不断放大的增量」这一判断，成为理解后续 GPU 与 ASIC 出货量与营收增速差异的关键。

这一点也是从芯片制造端了解未来 AI 芯片必须建立的基础认知。

2. **ASIC 阵营增速将超越 GPU：** 这是笔者 2025 年原文最核心、也最具前瞻性的判断。

2025 原文笔者的模型基于 CoWoS booking 数据推测：『2024 到 2027 年将进入 ASIC 的超级增长周期，三年 80% 的复合增长率』，25 年原文明确指出博通的 ASIC 业务(AI 业务中扣除交换器业务)将从 2024 年的 80 亿美元增长至 2027 年的 400 亿美元。

如今看来，2025 单单 ASIC 业务大约增长 50% 到 120 亿，当初预测 2027 年 400 亿将是打底的数字，目前乐观可以看到 500 亿以上，也就是说 2026-2027 年都是博通 ASIC 的超高增长年，这一点我们从 2026-27 CoWoS booking 数据也能看出端倪。

事实证明，2025 年 1 月笔者当初公布的模型极具前瞻的洞察力。

2025 年，博通接连拿下 Anthropic 超 210 亿美元、OpenAI 超百亿美元的 ASIC 大单，其 AI 相关营收暴增，股价与市值一路飙升，完全印证了 ASIC 赛道在推理市场爆发下的强劲增长。

原文中「2024-2027年ASIC的CoWoS消耗量复合增长率将达80%高于GPGPU」的判断，这一点在2026年博通CoWoS booking 100%+的年增量远高于英伟达的65%增量上完全验证，根据笔者的一手讯息，博通2027年的CoWoS增量将继续超越英伟达。

3. 英伟达面对ASIC的挑战将寻求策略转变：

2025 原文大胆预测：『NV 的业绩在 2025 年将突破 2000 亿美元，来到 2100 亿美元...但在 2026 年增幅下降』、『如果维持现有死守训练端的高毛利策略，2027 年将出现业绩零增长的可能』。

所以，2025 年原文，笔者也预见性地指出：「ASIC 必然是 NV 现阶段不想做(低毛利)但未来却不得不做的业务」、「NV 不可能坐以待毙...如果市场到了没办法再继续维持超高毛利的阶段，英伟达手上的武器一个一个放出来都是王炸」。

2025 年的市场走势与英伟达的动向完美呼应了笔者所有判断，英伟达 2025 财年营收确如预期突破 2100 亿美元大关，但市场已开始担忧其 2026 年增长率。

更重要的是，笔者在 2025 年一月文章中，预测英伟达一定会针对 ASIC 采取针对性行动，他不能也不会只死守训练高毛利市场。

随后，在 2025 年 1 月的 CES 首先推出 GB10 的桌面工作站芯片，3 月 GTC 推出 DGX Spark，9 月推出搭载 GDDR 的 Rubin CPX，全部都是针对推理市场的专用芯片。

10 月份的 GTC，老黄又扔出开放生态的 NVLink Fusion，这犹如攻入 ASIC 腹地的特洛伊木马。

12 月份以 200 亿美元的超高溢价收购 Groq，意图直取 ASIC 高能耗效比的命门。

这一系列动作，明确展现出英伟达进军定制化、低毛利市场以对抗 ASIC 侵蚀的战略意图，与笔者 2025 年 1 月的原文的预判完全一致。

当然笔者在 2025 年 1 月无法预测英伟达会采取什么手段，只能做出英伟达一定会有针对 ASIC 的战略转向与调整的预言。

4. 出货量（颗数）与营收（价值）的背离：

2025 年原文深刻指出，由于 ASIC 的 Interposer 面积通常小于 GPU，因此「采用不同方案的不同芯片，一片 CoWoS 能切割出的芯片数量天差地别」。

这导致在消耗相同 CoWoS 面积（产能）的情况下，ASIC 可以产出更多的芯片颗数。因此，比较出货颗数时 ASIC 可能快速逼近甚至超越 GPU，但在营收和利润上，单价高昂的 GPU 仍将占据主导。

这一细微但关键的区分，是理解 GPU 与 ASIC 市场份额之争的基石。

预测偏差部分：

1. GPU 增长韧性超乎笔者的预期：

2025 原文对 2026 年 GPU 增长「陡降」的判断可能过于悲观。

从 2025 年底至 2026 年初的产业动态看，由于「物理 AI」、机器人等新兴应用的强劲需求，以及英伟达 Rubin 等新一代平台带来的性能飞跃，训练端需求并未如预期般快速见顶，反而保持了强劲势头。

这使得 GPU 在 2026 年的 CoWoS 消耗占比和营收增长，比 25 年的原文预期的更为坚挺。

2. 技术路线融合加速：

2025 年原文的特点就是从芯片制造等物理层面，将 GPU 与 ASIC 视为两条相对平行的赛道去分析，是整个网路上唯一用芯片制造的视角去看待与分析 AI 格局演变的文章。

但实际上架构，软件，生态等技术融合趋势不断再加剧。

英伟达通过 NVLink Fusion 等技术开放生态，试图将 ASIC 纳入其体系；而一些 ASIC 也在增强可编程性。

两者的界限正在模糊，未来的竞争可能更多是「可编程通用加速器」与「高度定制化专用加速器」在不同场景下的混合架构之争。

2026 年的展望系列，我们还是会从芯片制造的硬件视角出发，并结合软件层面，更全面的来看待未来 AI 芯片的市场格局。

复盘结论：

总体而言，笔者 2025 年初的预测文章，在核心逻辑（CoWoS 为王、ASIC 增速将超越 GPU、英伟达需战略转型）和关键数据推演上，展现了极高的准确性和前瞻性。

成功地预见博通等 ASIC 设计公司的崛起，以及英伟达面临的增长拐点与战略抉择。

尽管在英伟达 2026 增长曲线的斜率上存在细微偏差，但文章建立的「以 CoWoS 产能为锚，穿透出货量与价值背离」的分析框架，依然是研判 2026 年乃至更长期 AI 算力格局最有力的工具。

第二章：战争的底层逻辑 - AI 算力需求大爆炸

要理解今天在 CoWoS 产能上的寸土必争，必须回到一切的起点：AI

不只是近年兴起的大语言模型（LLM），目前多模态，AI Agent 甚至物理世界模拟，让 AI 对算力近乎贪婪的渴求。

面对每年 5 倍增长的 token 衍伸出的算力需求，依靠摩尔定律两年翻一倍晶体管数量的算力增长已经完全跟不上节奏。

因为 AI 的出现，整个半导体行业迸发了无穷的潜力，在后摩尔定律时代竟然晶体管增加速度远超以前，记得数年前许多人云亦云的网民，高喊着摩尔定律已死，现在看来甚是可笑，谁知道再过几年又有啥新科技出现呢？

从芯片制造层面，面对 AI 恐怖的算力增长需求，芯片制造领域唯有不断缩小单位线宽同时不断加大芯片面积，一缩一放的加乘效果才能勉强跟上 AI 的节奏。

当然增加出货量也是一个办法，但这里就遇到了前段制程与 CoWoS 产能的瓶颈。传统的 CPU 架构在并行矩阵运算面前效率低下，也催生了专用加速芯片的黄金时代。

最终，AI 的出现推动半导体技术演进沿着三条相互交织又彼此竞争的路径展开：

1. 架构路径：从通用到专用，生态与效率的终极对决

GPGPU 的霸权之路： 英伟达的 CUDA 生态，将图形处理器锻造成了通用并行计算 GPGPU 的绝对王者。

其核心武器是极高的内存带宽（通过 HBM）和大规模流处理器阵列。

从 H200、GB200 到今年即将推出的“Vera Rubin”，都是这条路径的产物，性能提升直接与显存带宽、NVLink 互连规模挂钩。英伟达构筑的，是一个从硬件到软件（CUDA、AI 软件栈）的封闭而强大的帝国。

正如老黄在 CES 演讲所说，物理 AI 的 ChatGPT 时刻来了，AI 的第二拐点，从理解语言到理解物理世界，将还是由通用型 GPGPU 主导。

ASIC 的精准革命： 当 AI 工作负载，尤其是云端推理侧的负载日益固化，为特定算法（如 Transformer）定制的 ASIC 便展现出碾压级的能效比 Performance per Watt，和总拥有成本（TCO）优势。

谷歌的 TPU、亚马逊的 Inferentia/Trainium、微软的 Athena，以及中国的华为 Ascend，寒武纪 MLU 都是这条路径的先锋。

它们通过牺牲通用性，换取在特定战场上的极致性价比。而博通、Marvell、AI chip 等设计公司，正是通过为这些 CSP 云巨头定制 ASIC，撕开了万亿市场的一道口子。

2. 制程路径： 纳米尺度的军备竞赛

摩尔定律的延续是性能提升的物理基础。从 7nm、5nm、3nm 到 2026 年量产的 2nm，每一次制程跃进都意味着晶体管密度和能效的提升。

2024 年 3 月份台积电的刘德音与黄汉森在 IEEE 发表的文章，计算出不用十年，人类就可以制造出一万亿颗晶体管的 GPU 单芯片。

未来不再只是通过光刻等制程微缩这单一手段来提升晶体管数量，GAA、CFET 等立体结构的优化、2D 新材料以及先进封装每一个技术都能有效并持续的提升晶体管数量。

然而，单纯靠微缩已面临“功耗墙”和“存储墙”。2nm 晶圆的代工价格传闻高达 3 万美元，这已非所有玩家都能承受的赌桌入场费。

3.封装路径：超越摩尔，系统级创新的主战场

当制程微缩边际效益递减且成本飙升，“超越摩尔”（More than Moore）成为新的增长引擎。其核心就是先进封装，而 CoWoS 正是台积电为高性能计算打造的“皇冠上的明珠”。

CoWoS 的精髓在于异构集成。它不再追求制造一个巨大且良率堪忧的单片芯片，而是将多个小芯片，例如计算芯粒（GPU/ASIC 核心）、高带宽内存（HBM）、I/O 芯粒等，通过 Interposer 进行超高密度、超高带宽互连，集成在一个封装内。

CoWoS 带来了三大降维打击优势：

***突破光罩板极限：** 制造远超单个光刻机视场尺寸的超大芯片成为可能。

***混合搭配，最优解：** 可以集成不同工艺节点、不同功能的芯粒，实现性能、成本、功耗的最佳平衡。

***极致互连性能：** 硅中介层上的微凸块（ μ Bump）间距极小，使得芯粒间通信带宽激增，延迟和功耗大幅降低。

正因如此，无论是追求极致性能的英伟达 GPU，还是追求最佳 TCO 的云巨头 ASIC，但凡涉足顶级 AI 算力，都离不开 CoWoS。它从一项“使能技术”，变成了决定最终产品出货量的战略瓶颈资源。

后摩尔定律时代，More than Moore 成为主角，各种型态的先进封装技术孕育而生

我们从下面的例子可以清楚看出，后摩尔定律时代利用多种手段的晶体管推进速度。

2022 年英伟达采用 N4 制程的 Hopper 的晶体管数量为 800 亿。

2024 年采用 N4P 制程+D2D Chiplet 的 Blackwell 晶体管数量为 2080 亿。

2026 年英伟达将推出 N3P 制程的 Rubin 芯片，单 die 预计在 1680 亿晶体管左右，双 die 为 3360 亿晶体管。

2027 年集成度更高的 CPO，以及 CoWoS 的极限 4 die 合封，Rubin ultra 芯片晶体管总量将达到 6720 亿。

2028 年英伟达将推出 Feynman，采用 A16 制程，4 die 合封的晶体管总数将达到 8000 亿左右。

2030 年英伟达的更新一代芯片将采用 A14 制程，再加上利用 CoPoS 技术做到 8die 合封，晶体管总量达到 2 万亿。

所以利用芯片制程不断的微缩，加上不断放大面积的 interposer，单颗芯片的晶体管数量增长比摩尔定律时代更高。

2022 年的 800 亿，提升到 2030 年的 2 万亿，8 年 25 倍的提升，比摩尔定律每 2 年翻 1 倍，8 年 16 倍还来得更惊人。

全球 CoWoS 产能

对于 CoWoS 产能，尽管 OSAT 以及英特尔、三星等都在大力投资，但 2026 年的有效产能主要由 2025 年的投资决定，弹性有限。

更重要的是，垄断 CoWoS 市场的台积电，在 2028 年将推出方型基版的 CoPoS 取代 CoWoS，届时占 CoWoS 产能一半以上的英伟达将率先转入新技术，这将导致这两年为了满足市场刚扩产的 CoWoS 产能因被替换而大量闲置。

所以目前台积电对 CoWoS 的产能建设趋于保守，这对 AI 芯片客户来说不是一个好消息，目前得应对之策就是将短期外溢的订单转给 OSAT 或者精度要求不高的低端 ASIC 考虑英特尔 EMIB。

从现况来看，2026-2027 年 CoWoS 产能，将出现 2023-2024 年高度紧张度状态，从笔者一手讯息来看，2026 年 Q3 开始台积电 CoWoS 的稼动率将回到 100% 以上，直到 CoPoS 产能开出后又将迅速跌落。

目前台积电内部对这两年的 CoWoS 产能建设有很大的分歧。

因此，分析 2026 年的战局，必须首先看清 CoWoS 这座「军火库」的储备与分配。

未来 AI 芯片的竞争，是架构、制程、封装“三维战争”。

到了 2026 年，当制程进入 2nm 深水区，成本高企，架构路线（GPU vs. ASIC）出现根本性分叉时，再度紧缺的 CoWoS 先进封装的产能分配，就成了决定算力版图的最关键变量，没有之一。

第三章：2026 年 CoWoS 产能沙盘推演

基于笔者的讯息，我们对 2026 年台积电 CoWoS 产能及预订 Booking 情况进行建模分析。

根据笔者模型，台积电 CoWoS 产能近几年的爬坡如下：

2023 年底：约 12K/月

2024 年底：约 36K/月

2025 年底：约 80K/月

2026 年底（目标）：达到 ~120K/月。

对于 2026 年台积电 CoWoS 产能逐月提升过程，我们取一个不乐观也不保守的全年有效平均值：96K/月。

即 2026 年台积电 CoWoS 总有效产能约为： $96\text{K/月} \times 12 \text{ 个月} = 1,150,000$ 片。这是本次测算的总弹药基数。

CoWoS 产能分配的逻辑推演：

台积电的产能分配是一场基于技术、商业、地缘政治的复杂棋局。

核心考量如下：

技术绑定与生态深度： 英伟达是 CoWoS 最早期、最大胆的共同定义者和投资者，其架构（如 NVLink）与台积电 CoWoS 工艺深度耦合，享有最高优先级。

订单规模与战略押注： 苹果、英伟达、AMD 是台积电前三 VVIP 大客户，其巨额预付款和长期协议锁定了基础产能。不过苹果要到 2028 年才有自研 AI 芯片，这两年不需要 CoWoS 产能。

博通、Marvell 因承接谷歌、AWS、Meta 等云巨头天量 ASIC 订单，已跻身顶级 VIP 客户行列。

地缘政治与第二供应链： 美国对华技术限制，迫使中国头部 AI 公司，透过第三方等各种方式全力争取任何可能的 CoWoS 产能。

同时，ASIC 以及 AMD、英特尔乃至中国客户，都是台积电制衡英伟达分散客户风险的重要力量。

产品迭代与良率： 更复杂、集成度更高的封装（如集成更多 HBM、更大中介层）初期良率较低，实际有效产出需打折。

下图清晰展示了各主要玩家的争夺格局：

TSMC CoWoS Capacity & booking 2026-2027								
	2025	2026				2026	2027	REMARK
		Q1	Q2	Q3	Q4			
Nvidia	400,000	130,000	140,000	180,000	210,000	660,000	920,000	2026: Hopper10% , Blackwell60% Rubin30%
Broadcom	90,000	35,000	45,000	55,000	65,000	200,000	305,000	Google TPU v6 & TPU v7p: 65% Meta-Mtia v2 & v3 : 20% Open AI Titan (N3) Q4 出货5-10% Tomahawk 6 Swtich : 5-10%
AMD	55,000	12,500	12,500	30,000	35,000	90,000	140,000	2026: Mi300 series 约35% , Mi400 series 约65%
Marvell	60,000	12,500	15,000	15,000	17,500	60,000	60,000	AWS-Trainium 2 (N5) Microsoft -Maia 200 (N3E)
AI chip	20,000	15,000	15,000	15,000	15,000	60,000	90,000	AWS-Trainium 1 & 3 Anita (N3) AWS-Inferentia 2 (N7) Intel Gaudi 3 (N5), MS-Maia 100 (N5)
Annapurna	15,000	6,000	6,000	6,000	6,000	24,000	30,000	AWS-Trainium 3 Mariana
MTK	0	0	0	7,500	12,500	20,000	120,000	TPU7 v7e (single die)
Cisco	7,000	2,500	2,500	2,500	2,500	10,000	10,000	Silicon One series Swtich
Xilinx	15,000	2,000	2,000	2,000	2,000	8,000	10,000	Virtex UltraScale
Mircosoft	2,000	1,000	1,000	1,000	1,000	3,000	3,000	Athena
GUC	10,000	1,500	1,500	1,500	1,500	6,000	10,000	第三方 tape out
Sanechips	8,000	1,000	1,000	1,000	1,000	4,000	5,000	ZXR10-9900X Swtich
T - Head								PPU 2025 ban
Baidu								Kunlun 2 (5nm) / 2025 ban
Tencent								Zixiao v2(5nm) / 2025 ban
MetaX								C500降规版C280 / 2025 ban
Total	682,000	219,000	241,500	316,500	369,000	1,145,000	1,703,000	实际生产数量
TSMC	720,000	230,000	250,000	320,000	350,000	1,150,000	1,620,000	2026年底有效产能 120 kwpm 2027年底有效产能 150 kwpm
* Anthropic向博通采购210亿美元的TPU整机柜，预计100万颗TPU v7p，追加约4~4.5万片CoWoS，预计2026 Q2 开始交付								
* Xilinx Versale因成本不断攀升放弃CoWoS采用IoFO_LSI方案，只有需要HBM的最高端产品Virtex继续采用CoWoS方案								
* 台积电预计2028年开始量产CoPoS，届时大量CoWoS产能转入后将造成CoWoS产能过剩，所以目前TSMC不愿意大量扩建CoWoS，从26 Q4开始CoWoS稼动率将又回到100%以上，由于27年各家ASIC都是dual-die方案，加上Rubin ultra的4die设计，interposer将高达9.5x reticle，所以直到28年CoPoS量产之前，整个CoWoS产能都将是极度紧缺状态。								
* 苹果Inference ASIC Baltra 预计2027年Q1开始部署，取代M4/M5ultra，N3P制程，由博通负责高速互联，SerDes IP以及后段布线								

2026 年台积电 CoWoS 产能分配：

英伟达：2026 年 66 万片。年增 65%，依旧保持高增长。

尽管面临竞争，但其产品需求最旺、单价最高、技术最领先，仍将占据最大份额。

英伟达接近台积电 CoWoS 总产能 57.4%的预订量，遥遥领先其他 AI 芯片企业，几乎不受 ASIC 崛起而稀释，继续保持绝对主导的份额。

当然英伟达的 CoWoS 预订的增量，有很大一部分是来自 Interposer 面积放大的结果，2026 年推出的 Rubin 达到 5.5x reticle，比 Blackwell 的 3.3x reticle 大了 1.6 倍。

也就是英伟达在芯片出货数量不变的情况下,就必须增加 1.6 倍的 CoWoS 产能,或者说从英伟达在 Rubin 时代增加 60% 的 CoWoS 产能,芯片出货量与 Blackwell 时代相比是没有增加的。

当然整个 2026 年 Blackwell 还是出货主力,英伟达 65% 的 CoWoS 增量,必然是出货数量以及单价的双双齐涨的局面。

AMD: 2026 年 9 万片, 年增 64%。

多款 Mi300 系列已证明 AMD 的竞争力,刚刚开幕的 CES,苏大妈正式官宣 Mi400 系列的来势汹汹, 预计下半年开始出货。

从 CoWoS booking 数量来看,与 25 年相比有 64% 的增量,与英伟达的增幅几乎一致。这也标示着 AMD 对 Mi455 的信心十足。

Broadcom 博通: 2026 年 20 万片, 年增 122%。

主要客户谷歌 TPU 开始对外销售,对博通是利好,不过博通主要负责 TPU v6 以及 v7p, 偏向推理的 v7e 会在 2026 年下半年推出, 由联发科负责流片。

下一代的 TPU v8 还是会遵循 v7 的模式, 由博通与联发科两家分别下单台积电 CoWoS。

2026 年博通向台积电预定的 CoWoS 产能有 60~65% 给到 TPU

第二大客户 Meta 的 Mtia 芯片, 今年今年将推出第三代产品, Mtia v2 & v3 大约占博通 CoWoS 预订量的 20% 左右。

未来的大客户 Open AI 将于 2026 年底推出内部代号 Titan 芯片, 采用台积电 N3 制程, 预计占今年博通预订量的 5-10%, 2027 年将达到 20%。

2028 年苹果的 AI ASIC - Baltra 也将面世, 目前由博通负责高速互联, SerDes IP 以及后段布线, 预计 2026 年上半年进入 TO 阶段。

很显然, 博通是未来 ASIC 崛起的最大赢家。

Marvell 美满: 2026 年 6 万片, 年增 0%。

2026 年 CoWoS 预定数量与 2025 年持平，几乎是 AI 芯片最失意的厂家。主要是出货主力 AWS 下一代的 Trainium 3 转由 AI chip 设计。

2026 年主要客户还是 AWS 的 Trainium 2，新客户 Microsoft 采用 N3E 制程的 Maia 200 加入，避免了下滑。

AI chip 世芯：2026 年 6 万片，年增 200%。

2026 年 CoWoS 200% 的增幅，主要是拿下 AWS 的 Trainium 3 订单

2026 年出货包含少量 Trainium 1，决大部分为 N3 制程的 Trainium 3 Anita，加上 Inferentia 2 以及少量的 Intel Gaudi 3，以及微软上一代的-Maia 100。AI chip 的客户数量比博通还多，但出货量级都不高。

AWS 已暂停 Inferentia 3 的开发，转向以 Trainium 统一承担推理跟训练的工作负载，目前未见 Inferentia 3 的 TO 讯息。

Annapurna：2026 年 2.4 万片，年增 64%。

作为 AWS 的子公司，Annapurna 一直承担 AWS AI ASIC 的开发任务，同时也向台积电直接预定 CoWoS 产能，Trainium 3 的 Mariana 版本有别于 AI chip 的 Anita 版本，同时在台积电投片。

MTK 联发科：2026 年 2 万片。

作为台积电 CoWoS 的新进客户，目前联发科已调拨大量人力支持 ASIC 业务，AI ASIC 未来将成为联发科的重点业务。2026 年下半年主要承担 TPU v7e 的出货，2027 年为出货主力年，同时 2027 年将叠加 TPU v8e 的订单，2027 年 MTK 有机会出现 600% 的 CoWoS 同比增幅。

联发科目前已将 AI ASIC 最为为来核心业务，作为行业巨头，联发科的加入也将很大影响 ASIC 设计的市场格局。联发科这两年的 ASIC 业务虽然这两年高歌猛进，但由于只是做后段布线，缺乏博通强大的 IP，虽然增幅大，但单价较低，对于体量本就不小的全球第三 fabless 巨头来说，并不能带来营收的大幅度增长。

当然从 CoWoS 增量来看，联发科在 AI 以及端侧的布局非常积极，又有 ASIC 业务的高增长加持，将是这两年除了博通之外，ASIC 阵营的最大受益者。

剩下的台积电 CoWoS 客户的量级就都是小于 1 万片，其中微软自研 ASIC-Athena 还是由内部团队在台积电投片小批量的不断迭代推进。

GUC 创意还是小型 AI 芯片初创企业在 CoWoS 流片的首选，也是国内 AI 的重要第三方，毕竟 GUC 是台积电的亲儿子。

Xilinx 这个最早的 CoWoS 客户，因为 CoWoS 不断涨价，FPGA 又不如 AI 芯片的利润那么高，已经逐渐放弃高成本的 CoWoS，改由成本更低的 IoFO_LSI 方案。

剩下的两家交换机厂家思科与中兴微，因为其高端交换机有采用 HBM，所以一直以来也都是台积电 CoWoS 客户，只是预定量只有几千片的水平。

至此，我们得到了 2026 年各阵营的“弹药”配额：

英伟达：1,150,000 片 $\times$ 57.4% = 660,000 片

AMD：1,150,000 片 $\times$ 7.8% = 90,000 片

ASIC 阵营：1,150,000 片 $\times$ 32.5% = 370,400 片，其中博通 20 万片，超过一半。

其他（FPGA、Switch）：1,150,000 片 $\times$ 2.3% = 2,6450 片

从弹药分配来看，拿下整个 CoWoS 产能 65% 的 GPGPU 阵营还是拥有绝对的火力优势，甚至英伟达一家的火力就超过全球其他企业的总和。

第四章：超越数量 - 价值、生态与功耗的深层次博弈

然而，仅比较 CoWoS 还是会误判战局。虽然 CoWoS 数量与面积是一切的根本，但不同的封装方案，比如 single-die 以及 dual-die 方案，将导致 Interposer 面积出现很大的不同，每片 CoWoS 可切割数量有很大差别。

其中最显而易见的就是 Hopper 时代的每片切 29 颗，到了 Blackwell 时代的每片 14 颗，这正是 Interposer 不断放大的结果。

所以台积电 CoWoS 的产能增幅，对应的不只是 AI 芯片出货量数量的增加，还叠加了 Interposer 面积不断放大的增量。

又比如 2026 年谷歌的 TPU v7p 是 dual-die 的 D2D 方案，interposer size 在 2400mm² 左右，一片 CoWoS 可切割 16 颗左右。

而同一代针对推理的 TPU v7e，采用 single die 设计，interposer size 只有 1500mm² 左右，每片 CoWoS 可切数量超过 30 颗以上。

AI 芯片的 Interposer 越来越大的尺寸是明确的技术路线，目前 Interposer 是 3.3x 的 reticle size，2026 年的 Rubin 是 4~5.5x，而 2027 年 4-die 合封的 Rubin Ultra 将达到 9~9.5x。

所以不断放大的 Interposer 面积也是台积电 CoWoS 不断大幅度扩产的一大主因。

正因如此，以 CoWoS 的产能（消耗面积）增减幅度来计算企业 AI 营收增减幅度，会比企业的 AI 芯片出货颗数量增减来的更为准确。

AI 芯片战争的胜负，除了 CoWoS 消耗面积以外，还要在两个维度上评判：

算力维度：

一颗英伟达 B300 的 FP8 算力达 10 PFLOPS，而一颗定制推理 ASIC 的算力可能仅为其几分之一，即便是最强的 TPU v7p 也只有英伟达 B300 的一半，这还是不考虑今年与 TPU v7 同台竞技的 Rubin 的差距，如果用 Rubin 来对比差距将更大。

刚开幕的 CES 老黄说 Rubin 的性能将比 blackwell 在推理提升了 5 倍，训练提升了 3.5 倍，GPU 与 ASIC 的性能差距并没有缩小，反而是在扩大中。

因此，即使颗数接近，英伟达阵营输出的总算力（TFLOPS）很可能仍大幅领先。这是 GPU 通用架构的“蛮力”优势。

总算力领先的物理基础就是来自 CoWoS 消耗面积（晶体管）的多寡。

价值维度：

这是最残酷的差距。英伟达单颗 GPU 售价高达 3 万美元以上，未来会提升到 4-5 万美元。

而云巨头自研 ASIC 的“成本”仅体现为台积电的代工费用和博通的设计服务费，即便成本相差无多，但 ASIC 其“内部结算价”必然远低于 GPU 售价。

即便 ASIC 对外销售，我们可以用 Anthropic 向博通采购 210 亿美元的 TPU 为例，百万颗的 TPU v7p 扣除服务器等诸多配置，单颗对外售价在 1.5 万以下。目前最强的 ASIC 是采用最先进 N3P 制程的 TPU v7p，制程领先英伟达 Blackwell 一个世代，但其对外售价不到 Blackwell 的一半，这与刚才我们计算的 TPU v7p 的算力只有 B300 的一半，算力与售价差距大致上是对等。

从这一点来看，完全证明我们文章刚才所说，AI 芯片是多维度的比拼，不单单比摩尔定律比芯片制程，还要比谁的面积更大，能放进更多晶体管，最终表现在性能上的差别也决定他的最终价格。

因此，英伟达用 60% 的 CoWoS 产能，创造了整个 AI 加速芯片市场 70% 以上的收入和 90% 以上的利润。

这正是黄仁勋“6 个季度，5000 亿美元狂言”的底气 — 他卖的是“黄金”，而 ASIC 阵营在为自己锻造“精钢武器”。

生态锁死 vs. 专用解放：

英伟达的帝国城墙： CUDA 软件栈、庞大的开发者社区、优化的 AI 框架（TensorRT、Triton），以及 NVLink、NVSwitch 构成的系统级优势，构成了几乎无法逾越的生态壁垒。用户购买的是一整套最强的“交钥匙”解决方案。

ASIC 的破局逻辑： ASIC 的优势在于，对于 CSP 这类超大规模用户，当其软件栈完全自控，从 TensorFlow/PyTorch 框架到推理服务 Triton，且工作负载高度特化且稳定（如搜索推荐、广告排名、语音识别推理）。

所以自研 ASIC 能带来极致的 TCO（总拥有成本）优化和能效比。

它们用“专用化”换取“去英伟达化”的战略自由和长期成本节约。最终直指 CSP 采用自研芯片优化财务报表的内在动力。

这也说明了一个局限，ASIC 只有超大型 CSP 或者大模型等超大规模企业会使用，首先 ASIC 的资金以及人力投入巨大，但这两点已经确定了客户范围，所有用量不大的中小型用户都不可能使用 ASIC。

即便是购买现成的 ASIC，我们以 Anthropic 向博通采购 210 亿美元的 TPU 为例，这背后需要养一只极为强大底层系统工程师团队不断的进行深度迁移以及适配。

单这一项开支，就足以说明这并非普通企业所能承受的，当然目前 GPU 高昂的价格，让市场更愿意采用各种降本方案，可即便是购买现成 ASIC 的模式，大概也就能拓展到 Anthropic 这体量的大模型企业，很难再往下拓展。

系统级创新与功耗墙：

功耗即成本，散热即极限： AI 集群的功耗已从几十千瓦迈向兆瓦级，未来芯片功耗将飙升至数千瓦。风冷已到极限，液冷（包括冷板、浸没式）成为标配。

这不仅关乎电费，更决定了数据中心的物理设计和最大集群规模。

ASIC 的能效优势： 专用电路在执行特定任务时，能效通常远高于通用 GPU。这意味着在相同的供电和散热预算下，可以部署更多 ASIC 算力单元。

互连与封装创新： 战争远不止于单颗芯片。

CPO 共封装光学是突破“功耗墙”和“互连墙”的关键，CPO 展示了系统级互连的竞争。

系统架构创新，如华为的 384 颗 NPU 互连的 CloudMatrix 384，来挑战英伟达 NVLink 全互连系统的思路。

CoWoS 只是起点，其上的互连网络（NVLink, CXL, UCIe）、光引擎（CPO）的竞争同样激烈，而且每一个技术领先都有决定性的作用，目前英伟达在每一个维度上的表现都处于行业领先地位。

第四章：GPU 的技术反击与生态扩张：

2026 年开年 CES，黄仁勋与苏姿丰的演讲，清晰地勾勒出 GPU 阵营未来的技术路线图和反击策略，特别是对「物理 AI」这一新战场的定义，将深刻影响 GPU 与 ASIC 的竞争格局。

英伟达在 CES 宣告的战略意图：

1. 下一代「Rubin」架构正式亮相：

基于台积电 N3P 制程，并将 interpose 面积放大 1.4~1.6 倍，首次实现整合超过 3000 亿个电晶体的单一 GPU，晶体管总数达 3360 亿，较上一代晶体管数量提升 1.6 倍。

并搭载下一代 HBM4 记忆体，单 GPU 容量直奔 288GB 甚至更高，存储带宽突破 22TB/s，较上一代 Blackwell 提升 2.8 倍，可见 HBM4 相对于 HBM3e，在接口带宽以及 logic base die 的提升可谓相当惊人。
互连技术 NVLink 6.0 将提供超过 3.6TB/s 的 GPU 间直连带宽，较上一代 Blackwell 提升 1.8 倍。

推理性能比 Blackwell 高出 5 倍，训练的性能高出 3.5 倍。

Rubin 不仅是性能的跃升，更是英伟达巩固其在训练和复杂推理市场绝对领导地位的利器。

2. 物理 AI 的 ChatGPT 时刻：

这是黄仁勋演讲中最具震撼力的宣言。他认为，AI 的下一个前沿是理解和模拟物理世界，应用于机器人、自动驾驶、数字孪生、科学发现（如气候模拟、药物研发）等领域。

这些应用需要处理海量、多模态的传感器数据，进行复杂的物理仿真和实时决策，工作负载极度复杂、算法迭代快速。

为何老黄会这样说，因为「物理 AI」恰恰是通用 GPU 的绝对主场。

定制化 ASIC 在处理固定、已知的模型推理时效率极高，但面对物理 AI 所需的持续学习、多任务处理、快速算法适配等场景，其架构僵化的劣势将被放大。

GPU 凭借其无与伦比的可编程性和庞大的 CUDA 生态，能够灵活适应从计算流体力学到机器人控制等各种新兴物理 AI 任务。

因此，「物理 AI 的 ChatGPT 时刻」极大地扩展了 GPU 的应用边界和市场总量，为其增长提供了全新的可开发疆域，这是 ASIC 现有技术难以切入的赛道。

3. 收购 Groq：对 ASIC 的「釜底抽薪」之举。

2025 年底，英伟达宣布收购专注于低精度推理和极低延迟语音模型的初创公司 Groq。这笔收购远不止是技术补充，而是对 ASIC 阵营的战略反击。

Groq 的技术核心在于其 LPU（语言处理单元）架构，在特定推理任务（如大语言模型对话）上能实现远超 GPU 和传统 ASIC 的能效和速度。

英伟达通过收购 Groq，直接获得了在 ASIC 最具优势的「高能效推理」领域的尖端技术和产品。这使得英伟达能够以「内部 ASIC」的方式，正面迎战博通、谷歌等的定制化推理晶片。

这不仅是产品线的补充，更是商业模式的转变，从单纯销售通用 GPU，转变为提供「通用 GPU + 特定领域优化加速器（如 LPU）」的全栈解决方案。

这将有效遏制 ASIC 在推理市场的侵蚀，并可能夺回推理市场市占率的重要武器。此举加剧了 AI 加速器市场的融合与竞争。未来的界限不再是简单的 GPU 对 ASIC，而是「全栈生态公司」与「专项设计公司」的对决。

英伟达正在利用其资本和生态优势，将潜在的颠覆性技术收编入自身体系，战场的主导权还是掌握在英伟达手上。

AMD 则在 CES 公布 MI400 系列的细节，正式发布基于 3nm 增强版制程的「AMD Instinct MI400」加速器。核心参数瞄准超越英伟达当前旗舰，宣称在关键 AI

训练和推理工作负载上，实现相比 MI300 系列 100% 的性能提升，并强调其能效比优势。

AMD 持续推广其开放式软体栈 ROCm，并通过与微软 Azure、Oracle Cloud 等云服务商的深度合作，以更开放且更具性价比的方案争夺英伟达之外的市场份额。

苏姿丰强调，未来的 AI 计算将是多元化的，AMD 将为客户提供「第二选择」。

总而言之，2026 年的 GPU 阵营，并非消极防守。英伟达通过定义「物理 AI」新战场、收购 Grop 补强推理短板，正在从技术和生态两方面构建更深的护城河。

AMD 则坚定地走开放与性价比路线，蚕食市场。

GPU 的增长故事，正从单纯的「大模型训练」扩展到更广阔的「物理世界智能化」，这为其对抗 ASIC 的专用化攻势提供了战略纵深。

第五章：超越产能 - 生态、功耗与终局之战

CoWoS 产能决定了「弹药」数量，但战争的胜负还取决于「弹药」的效率、协同和最终产生的价值。

1. 生态系统的终极壁垒：

英伟达的 CUDA 生态依然是其最坚固的堡垒。数百万开发者、庞大的软体库、从训练到部署的全栈工具链，构成了极高的迁移成本。

尽管谷歌的 TensorFlow、PyTorch 等框架也在努力实现对不同硬体后端的支持，但在易用性、性能和社区支持上，仍与 CUDA 有差距。

ASIC 阵营的优势在于『垂直整合』，谷歌可以为 TPU 深度优化 TensorFlow，Meta 可以为 MTIA 定制模型。

但对于广大的企业和开发者而言，英伟达全面且最优的「交钥匙」方案仍然是最佳选择。

收购 Groq 后，英伟达有望将这一生态优势进一步延伸到特定推理场景。

2. 功耗墙与成本墙：

随着单晶片功耗突破千瓦级，数据中心的供电和散热成本已成为不可忽视的因素。

ASIC 凭借其专用架构，在能效比（Performance per Watt）上通常有显著优势。这也是云巨头在规模化部署推理服务时倾向采用自研 ASIC 的核心经济动因。

英伟达需要通过制程与封装技术的进步、架构创新（如稀疏计算、低精度推理）以及系统级优化（如液冷、CPO 共封装光学）来对抗 ASIC 的能效优势。

Rubin 架构和收购 Groq，正是其在性能和能效两端同时发力的体现。

3. 未来的融合与分野：

长远来看，GPU 与 ASIC 的界限会进一步模糊。英伟达可能会推出更多「可配置」或「领域专用」的加速器（类似收购 Groq 后的产品线）。

而 ASIC 设计公司（如博通）也可能会为不断强化 ASIC 的性能，并给客户提供更具灵活性的平台化方案。

未来的竞争，将是「高度优化的通用平台」与「深度定制但具有一定可编程性的专用平台」之间的竞争。

CoWoS 产能依然是基础，但在此之上，软体生态、能效表现、总拥有成本（TCO）和对新兴应用的适应能力，将成为决胜的关键。

2026，对峙与渗透的拐点

综上所述，基于对 CoWoS 产能的沙盘推演、对 2025 年预测的覆盘以及对最新技术动向的分析，我们对 2026 年 GPU 与 ASIC 的对决格局得出以下结论：

1. CoWoS 分配格局固化，英伟达主导地位难撼：

2026 年，英伟达仍将消耗台积电过半的 CoWoS 先进产能，这确保了其在高端训练和复杂推理市场的供给优势，并在 ASIC 固守的推理市场不断的尝试进攻。

ASIC 阵营份额依旧维持快速增长，主要来自 CSP 掌握的大量推理算力的增量和生力军头部大模型企业的加入，短期内依然无法动摇英伟达的根基，但却能在固守方阵内不断壮大与繁荣。

2. ASIC 在推理市场不断壮大，实现规模化突破，但 GPU 开辟「物理 AI」

新战线：

ASIC 凭借成本和能效优势，将在云巨头的大规模、固定模式推理场景中确立主流地位，并开始向 Open AI 以及 Anthropic 等头部大模型公司渗透。

然而，英伟达通过定义「物理 AI」这一全新、复杂且快速演进的赛道，为 GPU 找到了下一个爆发性增长点，有效对冲了 ASIC 在传统推理市场的冲击。

3. 竞争从「硬体对抗」升级为「生态与系统级对抗」：

英伟达收购 Groq 标志着战术的转变，从单纯防守转向「以彼之道，还施彼身」，用定制化能力反击定制化。

未来的竞争将是全栈能力的竞争：从芯片、互连、封装、系统到软体和开发者生态。拥有更完整生态和更强系统整合能力的玩家将赢得最终优势。

结论

以 2026 年台积电约 115 万片 CoWoS 产能为沙盘推演，我们测算出：ASIC 阵营（37.5 万片）达到 GPGPU 阵营（75 万片）刚好 50% 的水平，这个数据 2024 年为 52%，2025 年为 45%，2026 年为 50%。

也就是说 2026 年 ASIC 对比 GPGPU 的 CoWoS 占比提高了 5%。

这再次印证，笔者 2025 年原文所称，2024-2027 年为 ASIC 超级增长周期，其中 2026-2027 年将是周期高峰，大家可以再次翻阅 2025 年全球半导体展望中原文的模型。

面对 ASIC 基数较低的超高增长，GPGPU 在基数庞大的情况下，CoWoS 占比也没有大幅度的下滑，比笔者一年前预测的更有韧性，这除了英伟达 GPGPU 持续热销以外，还有 GPGPU 更愿意采用最新技术有较大关系，比如 2026 年的 Rubin 率先采用 4~5.5x reticle 的 interposer，2027 年很快推进到 9~9.5x，这个变量将直接翻倍。

而 ASIC 的绝对性能没有 GPGPU 那般的极致要求，2026 年 ASIC 的 Interposer 在 2.9~3x，在 2027 年也还是停留在 3.3x 的水平。

GPGPU 是面积快速放大但出货数量微幅增长，ASIC 是出货数量快速放大而面积微幅增长，最终胜败就表现就在 CoWoS 预定数据，ASIC 在出货数量增幅远高于 GPGPU 15% 以上，但在 CoWoS 产能的占比则是从 45%，提升 5 个点到 50%。

根据笔者模型，2027 年 ASIC 将来到 GPGPU 的 58%，ASIC 占比持续增加，意味着 2026-2027 笔者早早预测的 ASIC 迎来超级增长周期，增长率超过 GPGPU。

至于企业营收，那自然与 CoWoS 出货量成正比，芯片性能与面积（晶体管总数）成正比，同制程双颗的 dual-die 性能必然是高于 single-die 的芯片，文前有比较过性能与售价成同比例涨跌（TPUv7 与 B300），也就是性能高两倍，单价大概也会高两倍。

这里面多少 nm 制程与多大的面积都对性能（晶体管数量）有决定性的影响。

ASIC 的代表谷歌 TPU，除了 CSP 自研自用以外，开始向外提供，这标志着 ASIC 从正式迈入“规模化部署”以不断蚕食 GPGPU 领地。

然而，在商业价值（营收/利润）和算力总量上，英伟达凭借其极高的单价和通用算力优势，在 2026 年及之后一段时间内，仍将保持王者地位。

英伟达的帝国，将继续统治需要灵活性、创新性和全栈解决方案的广阔疆域（训练、新兴应用、中小企业、科研）。

ASIC 的诸侯国，将在超大规模数据中心内部，在推理、推荐、搜索等成熟且量大的固定战场上，建立起基于极致 TCO 和能效比的自治领地。

未来，我们更可能看到的是一个“GPU+ASIC”的混合算力世界：云巨头用英伟达 GPU 进行前沿模型研发和训练，同时用自研 ASIC 进行成本敏感的大规模推理部署。

战争的号角早已吹响，2026 年的 CoWoS 产能分配表，就是这场世纪算力大战最真实、最残酷的兵力部署图。

ASIC 群雄时代结束，谷歌/博通已成为共主，围猎与反围猎已经开始，而英伟达帝国依然强大。这场好戏，还在后头！

而更接近未来事实的是，这场战争并非一场你死我活的歼灭战，而是一场持久且复杂的“划界战争”。

随着战争的推进，各方势力意图提高竞争力去打败对手的同时，不断提高的技术能力，导致技术外溢，其产生的结果不一定是打败对手，而是如哥伦布一般，随着航海技术的提升，发现更为广阔的新天地。

AI 世界还有太多未知的疆域需要更高的技术才能去探索与挖掘。

未来 GPGPU 以及 ASIC 可能都是赢家。2026-2027 年 ASIC 的增幅将继续高于 GPGPU，2028 年融合了 LPU 的 Feynman 有没有可能带领英伟达在 ASIC 坚守的领地攻城拔寨，目前言之过早，未来谁主沉浮犹未可知？

而 GPGPU 以及 ASIC 在整体算力需求不断上涨的双赢背后，却始终站着一位终极大 BOSS，更大的幕后赢家不动声色冷眼旁观。台积电作为这场战争共同且唯一“军火商”，坐拥 CoWoS 产能的绝对定价权，将是无论哪一方获胜都不可或缺且毫无疑问的终极大赢家。