

1.国产 AI 芯片与海外技术差距

技术代差：以华为昇腾系列为例，其 950、960、970 三代产品对标英伟达 H 系列、B 系列、Blackwell 系列和 Rubin 系列，但 FP8 算力仅为对应英伟达产品的一半左右，主要受制程工艺限制；出货时间比英伟达晚两年（两代），整体落后英伟达约两代水平。

国内厂商竞争格局：国内主流 AI 芯片厂商（华为昇腾、阿里平头哥、昆仑芯 K800、寒武纪 590、海光、壁仞、天数、摩尔线程等）的产品在算力（FP16 为主，FP8 支持少）、显存（容量/带宽）、卡间互联三个硬件指标上未拉开显著代际差距，差异主要在 0.5 代以内。

2.AI 芯片市场供需关系

需求端爆发驱动：2025 年以来，推理需求因 agent 应用普及（如 Deep Research、编程 agent）和多模态生成（视频/图片）导致 token 数激增，远超传统问答场景；国内互联网大厂对 AI 芯片的需求 2025 年预计超 100 万片，供需缺口显著。

供给端地缘政治影响：英伟达 H20、RTX 6000D 等产品自 2025 年 7-8 月起被明确不推荐向国内互联网厂商销售；美国商务部禁止全球企业购买华为产品，导致美股/港股上市的国内大厂对华为芯片采购存在忌惮，国内其他 AI 芯片厂商产品近期销量激增。

市场波动加剧：算力需求爆发、产品迭代加速（如华为 910B/C 发布）、新应用涌现（如 DeepSeek），导致国内 AI 芯片市场供需关系每月均出现显著波动，企业需高频跟踪市场变化。

3.国内 AI 芯片厂商竞争要素

产品力：当前各厂商硬件规格参数接近，竞争转向软件生态、应用适配能力，如华为昇腾支持自研 HBM 显存和高速卡间互联，摩尔线程 S4000/S5000 产品兼容 LLM 推理需求。

供应链与产能：华为和寒武纪能稳定获取中芯国际产能，供应链自主性较强；台积电自 2024 年 11 月起暂停中国大陆地区 7nm 及以下 AI 芯片代工，国内厂商转向三星等替代产能存在不确定性，国内产能保障成为长期竞争关键。

“金主爸爸”支持：互联网大厂或运营商的订单（如百度对昆仑芯的支持）不仅带来资金，更提供应用场景打磨和下一代产品设计反馈，形成“需求-迭代”正向循环，华为因缺乏单一互联网大厂全包产能而略有劣势。

4.超节点技术趋势与争议

技术原理与优势：超节点通过扩大单机柜内高速互联卡数（如英伟达 NVL72 含 72 卡、华为 Kunpeng 384 含 384 卡），解决传统服务器跨节点通信带宽瓶颈（单机内 900GB/s vs 跨机 50GB/s），提升张量并行和专家并行效率，支持更大规模模型训练（如 50 万卡/100 万卡集群）。

头部厂商进展：华为凭借自研服务器、网络设备和 UB Mesh 组网协议，可基于 384 卡超节点轻松组建 50 万/100 万卡集群；阿里平头哥依托 CPU、存储产品协同，推出 128 卡超节点；中小厂商需联合服务器/网卡供应商组局，协同成本较高。

性能收益争议：超节点主要优化通信环节（占比 20%-30%），理论性能提升上限约 30%（通信占比 50%时提升一倍），远低于部分厂商宣传的 5-10 倍；且超节点造价高、功耗大，国内厂商大规模投入需谨慎评估性价比。

5.重点厂商点评：摩尔线程

产品竞争力：摩尔线程 S4000 及下一代 S5000 产品在算力、显存（HBM）、卡间互联等硬件参数上达到行业主流水平，支持 LLM 推理场景，兼容性较好，具备市场竞争力。

市场机遇：成立于 2020 年的摩尔线程凭借产品适配 LLM 推理需求快速崛起，2025 年过会上市，反映国内对 AI 芯片企业的资本支持；但其招股书显示收入依赖特定客户、与英伟达存在两代技术差距等问题，与行业普遍情况一致。

6.推理优化技术：P-D 分离与超节点协同

P-D 分离（prefill-decode 分离）：推理阶段分为算力密集型的 prefill 阶段和显存带宽密集型的 decode 阶段，分卡处理可显著提升性能，已成为业界标准；超节点通过将 decode 阶段的专家并行（如 256 个专家）集中在 64 张高速互联卡上，避免跨服务器通信带宽损失，优化 MoE 模型效率。

集群规模需求：以 DeepSeek 为例，推理需 4 台 H800 服务器（prefill）+14 台 H800 服务器（decode）组成 18 台集群，超节点可减少跨服务器数量，降低通信延迟。

7.下游采购趋势与行业焦虑

一线/二线厂商需求：国内互联网大厂（阿里、腾讯等）及二线厂商因担心错失 AI 机遇，对算力采购高度焦虑，二线厂商甚至将 AI 视为生存关键；京东等企业宣布“五年 1 万亿”AI 投入计划，反映行业对算力基础设施的长期重视。

供应短缺风险：当前市场面临 H20/A800 等海外芯片采购受限、国内产能爬坡缓慢的双重约束，预计 2026 年供需缺口仍将扩大，若出现 AI 杀手级应用（面向大众消费者），需求或进一步激增。



Q&A

Q:

目前国产 AI 芯片与海外技术相比进展到什么程度？

A:

以华为昇腾 950、960、970 三代产品为例，其硬件参数（FP8 算力、显存、卡间互联）明确对标英伟达 H 系列、Blackwell 系列、Rubin 系列三代产品。从硬件参数看，华为昇腾 950-970 的显存容量（950 为 128GB/244GB，960/970 为 288GB）、显存带宽（自研 HBM 显存，大致对标英伟达）及卡间互联能力与英伟达对应产品接近，但 FP8 算力仅能达到英伟达对应产品的一半左右，主要差距源于制程限制。整体而言，国内 AI 芯片（以华为为代表）与英伟达为首的海外产品存在约两代的差距，且出货时间晚两年。对于当前市场流通的国产 AI 芯片（如华为 910B/910C、阿里平头哥、昆仑芯 K800、寒武纪 590 等），从 FP16 算力、显存（容量/带宽）、卡间互联（国内约 400-780GB/s，英伟达 H200 已达 900GB/s）三个硬件指标来看，各厂商水平基本处于同一代，未产生代际差异。

Q:

国内 AI 芯片与英伟达产品的技术差距如何？

A:

以华为为代表的国内 AI 芯片产品，比英伟达的产品落后两代左右（约两年水平）。

Q:

国内 AI 芯片市场供需变化的主要原因是什么？

A:

国内 AI 芯片市场供需变化剧烈且频率快，主要来自需求和供给两方面。需求端，今年以来推理需求暴涨，因行业应用中 agent、多模态生成等场景产生的 token 数远超传统问答，例如分析单问题需处理约 100 篇文章，推理过程长、token 量大；供给端，地缘政治是重要影响因素，如英伟达 H20、RTX 6000D 等产品对国内互联网厂商的销售受限，美国商务部禁止全球企业购买华为产品，导致国内其他 AI 芯片产品近期销售旺盛。

Q:

如何看待国内 AI 芯片厂商的竞争态势，其优势和劣势体现在哪些方面？

A:

国内 AI 芯片厂商的竞争可从三个核心因素分析：一是产品力，当前硬件规格参数差距较小，未有厂商拉开两代产品优势，差异约在 0.5 代左右；二是供应链与产能，需求暴涨背景下，库存与产能决定销量，掌握供应链主动权是关键优势，厂商多尝试国内外两条腿走路，但上了 BIS 禁令清单的厂商海外供应链受限，国内产能中，华为和寒武纪能明确拿到中芯国际产能，华为产能保障较强，寒武纪情况也较好，而海外台积电自去年 11 月起已暂停中国大陆地区 7 纳米及以下 AI 芯片供应；三是是否有“金主爸爸”支持，即是否有互联网大厂或运营商等提供大额订单、资金支持及应用场景，以帮助产品打磨和下一代设计，并为供应链下单提供产量与资金保障，形成互相促进效应。其中，华为在竞争中独一档，不完全适用上述分析框架。

Q:

如何看待当前算力超节点成为产业趋势，以及上下游厂商（如华为、海光、寒武纪、阿里、腾讯等）推出超节点方案的竞争关系？

A:

超节点概念自 2024 年 3 月英伟达 GTC 大会发布 NVLink 272 产品后兴起，核心驱动力是解决大模型训练中的通信瓶颈。传统单机 8 卡服务器通过 NVLink 实现 900GB/s 的卡间传输速率，而跨服务器采用 IB 网卡等设备仅能达到 50GB/s（400Gbps），存在数量级差距。随着模型规模增长（如 GPT-4 的 670B 参数），单服务器 8 卡的张量并行能力不足，需跨服务器扩展，导致通信效率下降，超节点通过扩大单机（或机柜级）卡数并保持高速互联（如 NVLink 6 的 1.8T/s 带宽）缓解该问题。

不同厂商的超节点方案因技术积累和生态能力呈现差异化：华为凭借芯片

（910C/950/970）、网络设备（UB Mesh 组网、自研通信协议）、服务器等全栈能力，推出 384 卡超节点，支持轻松组建 50 万卡及 100 万卡集群（128 套 384 卡超节点即可组成 50 万卡集群），其单卡算力虽仅为英伟达 Blackwell 的 30%-40%，但通过规模优势提升整体性能；阿里依托平头哥的 NPU、CPU（玄铁）、存储产品体系，推出 128 卡超节

点，具备快速搭建超 64 卡节点的能力；而中小 AI 芯片厂商因缺乏服务器、网络设备等自研能力，需联合外部供应商合作，面临协同难度大、成本高、主导权不明确等挑战。

超节点的性能收益需理性看待：通信时间在训练任务中占比约 20%-30%（极端假设 50%），即便完全消除通信瓶颈，整体性能提升上限约为 1 倍，远低于部分厂商宣传的 5-10 倍。同时，软件优化（如 DeepSpeed 的专家并行技术、2025 年 2-3 月开源周发布的 6 篇优化论文）也能提升通信效率，进一步削弱超节点的绝对优势。当前超节点是明确趋势，但厂商需评估投入产出比，中小厂商盲目跟进可能不划算。

Q:

业内如何评价摩尔线程？其产品有哪些特点和优势？

A:

摩尔线程的产品硬件规格参数（算力、显存、卡间互联）能够满足上牌桌的要求，其 S4000 及下一代 S5000 产品表现较好。该公司成立于 2020 年，成立时间短但发展迅速，其产品较好地适应了 LLM 推理需求，尤其是在 LLM 满血版推理场景中具有优势。其训练产品（如 S4000）算力尚可，显存采用 HBM，显存容量和带宽不错，且具备卡间互联，支持多卡协同以满足 LLM 满血版推理的多卡需求。产品设计虽为两三年前（约三年前）完成，但能适配后续出现的模型，具有一定的前瞻性。此外，摩尔线程产品主打兼容，使用较为方便，业界第三方对其产品评价尚可。

Q:

超算技术在 P-D 分离、SV 等环节具体有哪些帮助？

A:

P-D 分离（prefill 与 decode 分开）已成为业界标准，能有效提升性能。将 prefill 和 decode 分在不同卡上执行，可避免单卡处理时算力与显存带宽利用不匹配的问题。超算技术支持构建推理小集群，以 DeepSeek 为例，其使用 4 台 H800 服务器进行 prefill，14 台 H800 服务器进行 decode，组成共 18 台服务器（每台 8 张卡）的小集群作为推理最小单元。decode 阶段通常需要更多卡数，因涉及 MoE（专家并行），理想状态下 256 个专家并行最好对应 256 张卡，实际中如将 256 个专家放在 64 张卡（每张 4 个专家），卡间通信数据量大。超节点配置（如 NV2 72）可实现 64 张卡通过 NVLink 高速互联，避免跨服务器导致的卡间互联带宽下降一个数量级，从而更好地满足大模型推理中卡间高速通信需求。

Q:

当前各家厂商 AI 芯片的总量、采购情况及未来采购规划如何？包括二线厂商如京东提出的五年 1 万亿投入计划。

A:

当前 AI 芯片需求缺口很大，一线及二线厂商均处于焦虑状态。从需求端看，AI 应用众多且厂商担心落伍，AI 是绝对不可错失的机会，无论是一线大厂（如阿里、腾讯）还是二线公司（部分与互联网结合紧密），都面临‘不投入 AI 可能导致公司倒闭、退市’的压力，例如京东提出五年 1 万亿投入，大厂间 1000 亿资金流动也反映 AI 缺口大。从供给端看，国内厂商无法买到英伟达 H20、A800（传闻），国内厂商产能不足以满足大厂需求，且

厂商对国内芯片厂商能力及绑定单一厂商存在担忧。尽管明年国内产能或有提升，但互联网应用增长和爆发仍将持续，若出现杀手级 AI 应用，行业估值可能再乘十倍，长期需求乐观。