

芯片电感行业交流 20260528

全文摘要

1、英伟达主流 GPU 三次电源配置

·GB200/300 电源器件配置：GB200 功耗为 1.2kW，GB300 功耗为 1.4kW，二者功耗相近，机柜采用 NVLink 架构，共包含 18 个计算托盘、9 个交换托盘。供电采用两级降压架构：48V 电源从 PSU 经 bus bar 输入背板后，首先经二级模块将 48V 转换为 12V，再通过 DRMOS 加电感组成的降压电路将 12V 转换为 GPU 适用的零点几伏电压。单计算托盘配置 300 颗 DRMOS、150 个集成双线圈电感，二者配比为 2:1，原因是电感物理封装为双线圈结构，电气上仅输出端相连，可配合 2 颗 DRMOS 使用，该两相电感可支持瞬间上百安培电流，DRMOS 为 90-100 安培规格。单机柜 DRMOS 总量约为 5700 颗（18 个计算托盘*300 颗+9 个交换托盘*约 40 颗），电感总量约为 2970 颗（18 个计算托盘*150 颗+9 个交换托盘*约 30 颗）；DRMOS 单价为 1-2 美金/颗，电感单价为 0.7-0.8 美金/颗，三次电源总价值约 1.2 万美金，配套的多相控制器用量较少可忽略不计。

·Rubik 电源器件配置：Rubik 功耗提升至 2.3kW，CPU 部分功耗从 Grace 的 0.3kW 提升至 0.5kW，同样采用 NVLink 架构，供电两级降压架构与 GB200/300 一致，目前 Rubik 及 Rubik

Ultra 的电源方案均已确定, Rubik 已进入发货阶段, Rubik Ultra 方案已公开。单计算托盘 DR MOS 用量提升至 360 颗, 其中 20 余颗供给 CPU 部分, 剩余 330 颗对应 4 颗 GPU, 单 GPU 对应约 80 余颗 DR MOS; 电感改为单线圈形态, 与 DR MOS 配比调整为 1:1, 调整原因是 Rubik 功耗提升后, 分开布置单线圈电感可优化散热设计, 避免双线圈集成封装的散热缺陷。电感单价降至 0.3-0.4 美金/颗, 虽然 DR MOS 用量较 GB300 单托盘增加 60 颗, 但电感单价减半, 整体单机柜三次电源总价值量仅较 GB300 增长约 20%, 用量增长远低于功率增长幅度。

·电源器件供应商格局: Hopper 时代电源器件供应商较少, 电感生产效率偏低, Blackwell 时代后大陆电感厂商进入英伟达供应链, 市场竞争加剧, 整体价格有所下行。台湾厂商乾坤的电感产品在可靠性、一致性、平面度管控等方面表现更优, 价格高于国产供应商, 后进厂商为进入英伟达供应链通常采取低价策略, 行业竞争格局呈现分层态势, 头部厂商凭借性能优势维持溢价空间, 新进入厂商以价格优势抢占份额。

2、英伟达 Rubik Ultra 电源方案进展

·Rubik Ultra 配置与进度: Blackwell 系列芯片所用电源芯片主要以英飞凌 MBS 为主, 瑞萨占比相对较低; 电感供应商主要包括乾坤、深圳联正、台湾国巨及部分欧美厂商, 其中联正在 Blackwell、Rubik 系列中的份额稍低。Rubik Ultra 相关信息在 2026 年 GTC 大会上展示的内容较为模糊, 当前无法获取精确的器件数量, 不

过从功耗及展示的模糊图片来看，其采用刀片式计算托盘横放的机架形态，单计算托盘 DR MOS 数量远高于 360 颗，预计超 400 颗，电感与 DR MOS 保持 1:1 配比，用量同步提升。方案确定性方面，Rubik Ultra 整体方案已基本定型，不会出现大幅调整，2026 年 9 月至年底将完成组装，交付节奏为 2026 年底-2027 年初交付样机。

·电感布局方案规划：Rubik Ultra 正面可摆放的电感数量充足，暂无需将电感放置在 GPU 板背面，电感 ASP 基本保持稳定。背面放置电感的方案暂不会在 Rubik Ultra 上应用，预计将在下一代费曼系列产品中落地。

3、英伟达下一代 GPU 电源技术趋势

·模块供电应用预期：a. 模块采用可能性分析：英伟达现有平台到 Rubing Ultra 均采用芯片加电感的传统分立供电方案，所用器件为标准品非定制化产品；同期 ASIC、AMD GPU 及国内 AI GPU 厂商均采用将三次电源 drummors、电感、部分电容集成的 3D 电源模块设计，目前市场猜测费半也有望采用该模块方案。b. 价值量差异对比：若采用模块方案，电感需求将迎来较大增量，定制化模块需配套定制化电感，设计复杂度更高，甚至可能用到 TLVR 电感，两类因素叠加下，电感价值量较当前零点几毛至七八毛的水平预计将近翻倍。

·TLVR 电感技术特点：a. 技术原理与核心优势：TLVR 技术是谷歌此前为解决 AI 机柜 MLCC 电容用量大、成本高的问题研发，

叠加近期电容涨价的驱动，目前技术发展已较为成熟，逐步成为市场主流，可在不影响电源设计功能的前提下节省电容用量。TLVR 电感外观与普通电感一致，但内部内置双线圈，若设计为两相、四相甚至未来八相电感，内部线圈数量将对应翻倍。b. 成本与应用场景：TLVR 电感生产对工厂的铜用料、结构设计、检测测试手段要求更高，成本较普通电感提升 2-3 成；该电感做模块时会封装到 VPD 内部，适配电源芯片和 PCB 的薄型化需求，尤其适配垂直供电背面放置的薄型化要求。

4、其他 AI 厂商电源方案对比分析

·特斯拉 Dojo 垂直供电方案：特斯拉是行业最早落地垂直供电的厂商，2021 年发布的 Dojo 超级计算机首次公开该技术方案，每颗 D1 芯片配备 6 个 3D 结构电源模块，单个模块由 2 颗电源芯片、1 个电感加部分电容组装而成，配套液冷散热系统可及时带走模块运行热量。该方案早在 2019 年就已启动研发，模块经过多代迭代，但由于 Dojo 量产时间较晚、仅供给特斯拉自用，整体应用规模有限。

·AMD MI 系列模块供电方案：AMD MI 系列 GPU 全线采用模块供电方案：

a. 用量与功耗对应关系：500W 功耗的 MI200 系列配备 23 颗电源模块，对应 46 颗电源芯片；1000-1400W 功耗的 MI300 系列模块用量提升至 30-37 颗。

b. 价值量测算：单模块单价 10 美金以上，单 GPU 对应模块总

价值量达 300 美金以上，是英伟达 Hopper 分立供电方案的 2 倍以上。

c. 成本拆解：单模块中电源芯片占 2-4 美金，定制化电感占 1-2 美金，其余成本来自 MLCC 电容、PCB、加工测试等环节，模块组装良率低于芯片级 95%以上的水平。

d. 布局优劣势：采用正面模块布局，优势为可选用高规格电感降低导通损耗，同时可借助 GPU 正面大散热器带走模块热量；劣势为水平供电的端到端效率低于垂直供电方案，不过当前产生的损耗仍在可承受范围内。

·AWS Trainium 供电方案：AWS Trainium 系列 TPU 采用 VPD 背面垂直供电方案，500W 的 Trainium TPU 配备 24 个电源模块，总价值量达 200 美金以上。模块用量并不与功率成正比，核心原因包括：一是板卡空间有限，无法随功率提升无限叠加模块；二是散热技术持续优化，液冷普及后可减少电源芯片用量；三是电源芯片效率呈抛物线特征，在 20%-50%负载区间效率最高，设计需预留足够余量，并非完全匹配热设计功耗；四是电源需扛住瞬时尖峰功耗，用量需兼顾冗余需求。行业通用配置参考为

500W 方案用 23-24 颗模块	1000W
--------------------	-------

方案约 30 颗，1400W 方案约 30-37 颗，边际增量持续递减。同时模块自身也在持续迭代，迭代速度较慢以保障方案稳定性，性能升级后单模块价值量会同步提升。

·谷歌定制大模块供电方案：谷歌采用定制化大尺寸垂直供电模块，

与其他厂商的指甲盖大小通用模块不同，模块宽度相当于四根手指，目前已迭代至第三代，今年发货的 V7 平台主要采用 1.5 代、第二代模块。技术上集成已开放专利的 TLVR 跳压电感，将部分电容埋入 PCB 内部，代工厂商包括泰坦、伟创力，后续米 8 平台将引入更多供应商以保障供应、降低成本。该方案的优势在于可最大限度缩短模块输出端到芯片用电端的距离，减少电流路径损耗，端到端效率显著高于平铺供电方案。劣势则包括大模块易因温度不均发生变形翘曲，单个模块损坏后维护难度大，需配套专用冷板散热，整体开发成本更高，模块良率测试也有较高技术门槛。

5、电源核心器件迭代与瓶颈分析

·电源设计核心瓶颈：当前电源设计仍以硅基 MOS 为核心功率器件，碳化硅、氮化镓等新型功率器件仅适用于一阶、二阶电源场景，暂不具备在该类电源中应用的条件。器件迭代核心围绕薄型化、适配散热与空间要求展开：一方面，MOS 处于持续迭代状态，为简化散热系统、满足产品背部安装时塞入设备更下层的需求，器件需向更薄方向升级，具体实现方案包括将芯片嵌入 PCB 内部，对应的技术优化方向包括降低芯片阻抗、提升 PCB 复杂度（增加 PCB 层数、铜用量、过孔数量）以解决嵌入式芯片的散热问题。另一方面，电感同步向多相化方向升级，当前普遍采用两相电感，未来将迭代为四相甚至 TLVR 电感，要求在同等体积下实现更多相数，核心难点在于电感变薄、相数增加时都会导致感

量下降，需要采用更高性能的粉芯材料突破这一瓶颈。

·电感供应商与迭代逻辑：电感供应商分为不同梯队，第一梯队厂商包括乾坤、博科、顺络，供应产品与英伟达所用电感供应商重合度较高，第二梯队追赶厂商包括麦捷及其他未上市中小厂商，不同梯队产品差距显著：空载时感量差距可达数微亨，带载后感量下降速度更快、发热情况更突出。电感迭代的核心要素包括两点：一是磁材的选择与配方配比，二是气息与产品形状设计，电感产品的核心评判标准包括阻抗高低、带载运行后的发热表现、平面度管控、长期可靠性与一致性，新产品开发阶段核心考察电气性能。电感迭代效率较高，若首版产品客户测试未达要求，优化周期较短，后发厂商可通过逆向竞品的工程手段实现快速追赶。

6、IVR 集成供电技术发展展望

·IVR 技术原理与量产进展：IVR 属于芯片层级电压转换技术，核心作用是将中间电压转换为 GPU、CPU 可使用的 0.6V-0.75V 等级低电压。其技术实现核心依赖两类核心器件：一是硅电容（也叫嵌入式电容），采用 CMOS 工艺及纳米级蚀刻技术制作，替代传统陶瓷堆叠电容，可大幅缩小电容体积，不同厂商的蚀刻工艺存在差异但不影响技术落地；二是芯片化小型电感，由于 IVR 开关频率最高可达 150 兆，远高于当前 GaN MOS 的 1 兆，对应器件尺寸可缩小十几倍至二十几倍，目前 Intel 已研发出空心电感等芯片化电感方案。当前 IVR 技术仍存在诸多工程难题尚未解决，距离成熟量产仍有较长周期，3-5 年内难以落地，大规模

商用预计要到 2030 年左右。传统 GaN MOS 目前仍可在 48V 转 3.x 伏、12V 转 3.x 伏的前级电压转换场景应用,不会完全被替代。

- IVR 过渡阶段方案: IVR 技术落地将分为过渡阶段与终极形态两个阶段推进。过渡阶段的技术方案为将开关频率从现有 1 兆提升至 10 兆,相关器件可嵌入 GPU 基板或主板 PCB 内,英飞凌、MPS 等头部厂商已率先布局该类过渡方案。IVR 的终极形态是将 IVR 电路直接放置在芯片旁甚至集成到芯片内部。当前功率半导体领域传统 GaN MOS 技术已发展十余年,相关性能提升已接近瓶颈,采用更新工艺带来的性能提升比例越来越小,亟需 IVR 等新技术路线推动行业持续发展,目前多家布局 IVR 相关技术的厂商已在与马维尔等企业合作推进开发。

7、电感产能与扩产瓶颈分析

- 电感升级产能消耗规律: 电感用量与芯片呈 1:1 对应关系,形态为一颗 Drain MOS 配一颗电感。电感总用量与功率无绝对正比关系,具体关联度受产品设计、散热条件、布局规划、应用场景等多因素影响,无通用计算公式可直接套用。单颗电感从单相升级为双向、四向,或是从非 TLVR 类型升级为 TLVR 类型时,产能消耗接近线性增长,不存在剧烈非线性增长情况,生产效率仅受模具、工艺差异小幅影响,无重大生产障碍,更细化的行业信息可咨询专业电感厂商。

- 电感扩产核心瓶颈: 电感扩产的核心瓶颈及相关情况如下: a. 扩产周期: 电感生产依赖上游设备,目前上游设备采购交期延长,

叠加新产线新建、调试需约半年时间,整体扩产周期约 1 年;b. 设备属性: 扩产所用设备以通用型为主, 仅因各家生产工艺不同存在小幅差异, 其中热压成型工艺对设备压力控制精度要求较高, 烧结工艺对温度管控要求较高;c. 原材料供应: 电感核心原材料为铜、铁、钴、镍等金属及粉芯材料, 国内磁性材料、粉芯材料供应商充足, 原材料产能无瓶颈, 仅当前价格存在上涨压力。

8、英伟达 GPU 电源用量差异补充说明

·功率与用量差异原因: 从 GB300 到 Ruby, GB300 采用双线圈电感, 有效电感共 300 个, Ruby 采用单线圈电感, 共 360 个, 电感用量仅增长 20%, 但功率提升幅度远高于该比例, GB300 功耗为 1.4kW, Ruby 功耗达 2.3kW。二者差异核心原因是单颗电感、芯片的电流承受能力提升, 且芯片在尺寸缩小的同时电流能力有所增强, 无需大幅增加电感或芯片用量即可实现功率提升。目前没有绝对公式可直接计算所需电感数量, 即便厂商协助客户开展相关设计, 也无法直接确定用量, 最终用量由客户结合多方输入完成仿真等设计环节后自行确定。

Q&A

Q: 从 GB200、GB300 到 Rubin 及 Rubin Ultra, 服务器三次电源的设计方案与架构有何变化?

A: GPU 功耗持续提升, 三次电源架构保持 48V 背板经二级模块转 12V、再通过 DrMOS 与电感降压至 0.xV 的路径。GB200/300

采用三段电感，单机柜计算托盘 18 层×约 300 颗 DrMOS+150 个电感，交换托盘 9 层×40–50 颗 DrMOS+20–30 个电感；Rubin 代电感改为单线圈设计，计算托盘每层 DrMOS 增至约 360 颗，电感单价降至 0.3–0.4 美元；Rubin Ultra 方案已定，采用刀片式机架，DrMOS 预计 400 余颗，电感维持 1:1 配比。价值量方面，GB200/300 单机柜 DrMOS 约 6000 颗、电感约 3000 颗；Rubin 代因大陆厂商入局竞争加剧，ASP 下降，总体价值量增幅有限。

Q: DrMOS 与电感的规格参数如何？

A: 电感通常为两相设计，支持瞬时电流上百安培；DrMOS 芯片规格集中在 90–100 安培范畴。

Q: Rubin 与 Rubin Ultra 的三次电源方案是否已确定？

A: Rubin 方案已定并开始发货，采用 NVL7 层架构，计算托盘每层 DrMOS 约 360 颗，交换托盘每层约 40–50 颗；Rubin Ultra 方案已公开确定，因采用刀片式机架且细节未完全披露，DrMOS 数量预计增至 400 余颗，电感保持 1:1 配比，具体待样机交付验证。

Q: Rubin 代电感与 DrMOS 配比为何从 GB200/300 的 2:1 变为 1:1？

A: 电感技术迭代优化散热设计：此前双线圈封装可减小面积但热

管理难度大；Rubin 代功耗提升，改为单线圈独立摆放以改善散热，故配比回归 1:1。

Q: 从 GB200/300 到 Rubin

DrMOS

数量增加但电感 ASP 减半，总体价值量变化如何？

A: 单机柜 DrMOS 数量从约 6000 颗增至约 6500 颗，电感因配比变化总数量增加但单价降至 0.3–0.4 美元，总体价值量变化有限。主因是供应链竞争加剧，大陆电感厂商入局压低价格，高性能厂商价格仍略高。

Q: Rubin 代三次电源芯片及电感的供应商与份额分布如何？

A: 电源芯片主要供应商为英飞凌、瑞萨；电感供应商包括乾坤、深圳联正、台湾国巨及欧美厂商，格局与 Blackwell 代相似。

Q: Rubin Ultra 三次电源方案细节及电感 ASP 趋势如何？

A: Rubin Ultra 方案已定，DrMOS 数量预计 400 余颗，电感维持 1:1 配比，ASP 与 Rubin 代相近。电感目前仍位于 GPU 板侧边，背面供电方案预计延至 Feynman 代；若采用电源模块，单颗电感价值量可能翻倍。

Q: TLVR 电感是否封装于垂直供电模块中？其技术特点与成本影响如何？

A: 是，TLVR 电感用于模块化设计以适配低高度要求。该技术通过辅助绕组减少电容用量，内部含多线圈结构，设计复杂度提升，成本增加 20%–30%，需配合硅电容与定制工艺实现。

Q: AMD MI300、AWS Trainium 及谷歌的三次电源模块方案与价值量如何？

A: AMD MI200/300 系列采用水平供电模块，单 GPU 使用 23–30 余颗模块，单模块价值约 10 余美元，总价值量约 300 美元；AWS Trainium 采用垂直供电，500W GPU 用 24 颗模块，总价值量约 200 余美元；谷歌采用大型定制模块，由 Titan、伟创力供应，集成 TLVR 电感与埋入式电容，用于 V7 平台，但面临散热与翘曲挑战。

Q: 电源模块的成本构成如何拆分？

A: 单模块中 DrMOS 成本约 3 美元，定制电感 1–2 美元，其余为 PCB 与多颗标准 MLCC 电容；电容为通用标品，非定制化设计。

Q: 电源模块封装的良率水平及扩产难点有哪些？

A: 模块封装良率低于芯片级，因多部件组装与多次回流焊工艺复杂；扩产周期约一年，主要受设备采购交期及产线调试影响；粉芯材料供应充足但价格波动。

Q: GPU 功耗提升是否导致电源模块数量与价值量线性增长?

A: 非线性关系。模块数量受板面空间、散热方式及供电拓扑优化影响: AMD MI300 中 1kW 型号用 30 余颗模块, 1.4kW 型号亦为 30 余颗; 模块迭代可提升单模块性能, 价值量可能上升, 但数量增幅受工程设计制约。

Q: 谷歌大型定制模块方案的核心优势与坚持原因是什么?

A: 核心目标是缩短供电路径至芯片用电端, 显著降低线路损耗、提升端到端效率; 尽管模块自身转换效率略有下降且面临散热、翘曲等挑战, 但系统级效率优化使其成为必要选择。

Q: 电源模块技术迭代中, 当前主要瓶颈环节是什么?

A: 瓶颈集中于电感与 DrMOS 的微型化与性能提升: 电感需在减小体积下维持感量, 并满足平面度与可靠性; DrMOS 需降低阻抗、提升电流密度。碳化硅、氮化镓暂不适用于三次电源, 硅基 MOS 仍是主流。

Q: IVR 技术演进对三次电源模块架构有何影响?

A: IVR 技术将供电电路与芯片共封装, 需硅电容与微型电感, 开关频率提升至数十至百兆赫兹。当前处于研发阶段, 工程挑战较多, 预计 2030 年左右成熟; 过渡方案可能将模块嵌入主板, 由

英飞凌等推动。

Q: 电感技术升级对单颗电感产能消耗的影响如何?

A: 单颗电感复杂度提升对产能消耗呈线性增长, 生产效率略有下降但非主要瓶颈; 具体影响需结合工艺与测试环节评估, 建议咨询电感厂商获取细节。

Q: 从 GB300 到 Rubin, 电感有效数量增幅低于功耗增幅, 原因是什么?

A: 单颗电感与 DrMOS 的电流承载能力通过技术迭代显著提升, 使器件数量增幅低于功耗增幅; 具体配置由客户基于仿真、散热及布局综合设计确定, 无固定计算公式。